

Tarea S3.01. Introducción a BigQuery y SQL en la Nube

Para hacer: Recibir una calificación

Descripción

Bienvenido a la nube. En este sprint, darás el salto de trabajar en local (MySQL) a trabajar con Google BigQuery, un Data Warehouse serverless diseñado para el análisis de datos a gran escala.

En el entorno empresarial actual, el analista no acostumbra a crear bases de datos desde cero, sino que debe conectarse a repositorios existentes (Data Lakes), comprender los costes de la nube y preparar los datos brutos para el análisis (ELT).

⚠ Importante

» **Control de Costes:** En BigQuery, cada consulta cuesta dinero. Antes de ejecutar nada, fíjate siempre en el mensaje del validador ("Dry Run") arriba a la derecha.

» **Ubicación de los Datos:** Asegúrate de que tu Dataset esté en la región EU (Multiple regiones) o las conexiones fallarán.

Limitaciones del Sandbox

La zona de pruebas de BigQuery (Sandbox) está sujeta a los siguientes límites:

» Se aplican todos los límites y cuotas habituales de BigQuery.

» Tienes 10 GB de almacenamiento activo y 1 TB de datos de consulta procesados cada mes sin coste alguno.

» ⚠ **Caducidad:** Todas las tablas, vistas y particiones caducan de forma automática después de 60 días.

» No admite funciones avanzadas como: Transmisión de datos (Streaming), DML (UPDATE/DELETE) o el Servicio de transferencia de datos.

Nivel 1: Entorno e Ingesta Híbrida (Code-First)

Escenario:

Acabas de llegar a la empresa. El equipo de Ingeniería de Datos ha dejado los ficheros históricos en el Data Lake corporativo.

Tu primera misión es diseñar y crear el entorno de trabajo. El CTO exige profesionalidad: no volcaremos datos sin orden, sino que implementaremos una Arquitectura Medallion.

Ejercicio 1: Arquitectura de Datos (Lógica vs. Física)

Antes de manipular la consola, debes entender la diferencia entre lo que diseñamos y lo que construimos:

» Arquitectura Lógica (Capas de Datos): Es el diseño conceptual. Organiza los datos según su nivel de calidad (Bronze, Silver, Gold).

» Implementación Física (Datasets): Es el recurso real en Google Cloud. En BigQuery, utilizaremos Datasets (contenedores) para materializar físicamente estas capas lógicas.


🔧 Tareas:

Implementar físicamente la arquitectura lógica creando tres Datasets dentro de un mismo proyecto para centralizar la facturación y los permisos.

👉 Crea un **Nuevo Proyecto** en Google Cloud llamado:

sprint3-analytics-[el-teu-nom].

Lo puedes crear por la UI, pero si lo haces por Consola (gcloud CLI) tiene un plus.



```
Google Cloud SDK Shell
You are signed in as: [a.armentano73@gmail.com].

Pick cloud project to use:
[1] sprint3-498289
[2] Enter a project ID
[3] Create a new project
Please enter numeric choice or text value (must exactly match list item): 3

Enter a Project ID. Note that a Project ID CANNOT be changed later.
Project IDs must be 6-30 characters (Lowercase ASCII, digits, or
hyphens) in length and start with a lowercase letter. sprint3-analytics-albert
Waiting for [operations/create_project.global.4987826366342515264] to finish...done.
Your current project has been set to: [sprint3-analytics-albert].

Not setting default zone/region (this feature makes it easier to use
[gcloud compute] by setting an appropriate default value for the
--zone and --region flag).
See https://cloud.google.com/compute/docs/gcloud-compute section on how to set
default compute region and zone manually. If you would like [gcloud init] to be
able to do this for you the next time you run it, make sure the
Compute Engine API is enabled for your project on the
https://console.developers.google.com/apis page.

Created a default .boto configuration file at [C:\Users\POL\.boto]. See this file and
[https://cloud.google.com/storage/docs/gsutil/commands/config] for more
information about configuring Google Cloud Storage.
The Google Cloud CLI is configured and ready to use!

* Commands that require authentication will use a.armentano73@gmail.com by default
```

Para demostrar tu dominio total de la plataforma, crearás cada uno de los datasets utilizando un método diferente:

- » Dataset Físico **sprint3_bronze** → Capa Lógica Bronce (Datos Crudos)
 - Función: Datos crudos tal como llegan de la fuente.
 - Método: Utiliza la Interfaz Gráfica (UI) de BigQuery (haciendo clics).
- » Dataset Físico **sprint3_silver** → Capa Lógica Silver (Datos Limpios)
 - Función: Datos limpios, tipados y deduplicados.
 - Método: Utiliza código SQL (CREATE SCHEMA).

```
1 CREATE SCHEMA `sprint3-analytics-albert.sprint3_silver`  
2 OPTIONS (  
3   | location = 'EU'  
4 );
```

ID de trabajo	sprint3-analytics-albert:EU.bqjob_57735210_19e96b97d53
Usuario	a.armentano73@gmail.com
Ubicación	EU
Hora de creación	5 jun 2026, 9:39:59 a.m. UTC+2
Hora de inicio	5 jun 2026, 9:39:59 a.m. UTC+2
Hora de finalización	5 jun 2026, 9:40:01 a.m. UTC+2
Duración	1 s
Bytes procesados	0 B
Bytes facturados	0 B
Milisegundos de ranura	0
Prioridad del trabajo	INTERACTIVE
Usar SQL heredado	false
Etiquetas	

- Dataset Físico **sprint3_gold** → Capa Lógica Gold (Datos de Negocio)
 - Función: Datos agregados listos para informes y paneles de control (dashboards).
 - Método: Utiliza Cloud Shell (Línea de órdenes bq).

```
C:\Users\ALBERT\Google Cloud CLI>bq --location=EU mk -d sprint3-analytics-albert:sprint3_gold
Dataset 'sprint3-analytics-albert:sprint3_gold' successfully created.
```

Ten en cuenta la ubicación de los datos originales para decidir la ubicación física de los tres Datasets.

📍 Nota: Aunque sean capas lógicas diferentes, físicamente tienen que vivir en la misma región para poder "hablar" entre ellas sin costes de transferencia.

Ejercicio 2: Ingesta en Capa Bronce (Conexión DDL)

Un analista profesional automatiza las tareas. Ahora que tienes tu arquitectura a punto, poblaremos la primera capa (Bronce) sin mover los datos originales, creando Tablas Externas que apunten al Data Lake.


🔧 Tarea:

Escribe y ejecuta las sentencias CREATE EXTERNAL TABLE para conectar los siguientes ficheros al dataset sprint3_bronze. Presta mucha atención a las "Notas Técnicas", ya que no todos los archivos tienen el mismo formato.

Taula	Domini	Ruta al Núvol (URI)	Notes Tècniques
transactions_raw	ERP	gs://bootcamp-data-analytics-public/ERP/transactions.csv	Delimitador: ; (Punt i coma)
companies_raw	ERP	gs://bootcamp-data-analytics-public/ERP/companies.csv	Capçalera: Ignora la 1a fila. Defineix l'esquema manualment perquè tot és text.
american_users_raw	CRM	gs://bootcamp-data-analytics-public/CRM/american_users.csv	Estàndard.
european_users_raw	CRM	gs://bootcamp-data-analytics-public/CRM/european_users.csv	Estàndard.
credit_cards_raw	CRM	gs://bootcamp-data-analytics-public/CRM/credit_cards.csv	Estàndard.

👉 Entrega:

El código SQL utilizado para transactions_raw y una captura de pantalla con las 5 tablas creadas.



The screenshot shows the Google Cloud BigQuery console. On the left, the project hierarchy is expanded to 'sprint3-analytics-albert', showing a list of tables including 'transactions_raw'. The main panel displays a SQL query titled 'Consulta sin título' with the following code:

```
1 CREATE EXTERNAL TABLE `sprint3-analytics-albert.sprint3_bronze.transactions_raw`  
2 OPTIONS (  
3   format = 'CSV',  
4   uris = ['gs://bootcamp-data-analytics-public/ERP/transactions.csv'],  
5   field_delimiter = ';',  
6   skip_leading_rows = 1  
7 );  
8
```

Below the query, a status message indicates 'Se completó la consulta'. The 'Recientes' tab shows the query was executed at 10:32 a.m. The 'Resultados de...' tab shows a message: 'Esta declaración creó una nueva tabla con el nombre transac...', with a button 'Ir a la tabla'.

```
21 CREATE EXTERNAL TABLE `sprint3-analytics-albert.sprint3_bronze.companies_raw`  
22 (  
23   company_id STRING,  
24   company_name STRING,  
25   address STRING,  
26   city STRING,  
27   country STRING,  
28   phone STRING,  
29   email STRING  
30 )  
31 OPTIONS (  
32   format = 'CSV',  
33   uris = ['gs://bootcamp-data-analytics-public/ERP/companies.csv'],  
34   skip_leading_rows = 1  
35 );
```

```

7 CREATE EXTERNAL TABLE `sprint3-analytics-albert.
  sprint3_bronze.american_users_raw`
8 OPTIONS (
9   format = 'CSV',
10  uris = ['gs://bootcamp-data-analytics-public/CRM/
  american_users.csv'],
11  skip_leading_rows = 1
12 );

```

```


7 CREATE EXTERNAL TABLE `sprint3-analytics-albert.
  sprint3_bronze.european_users_raw`
8 OPTIONS (
9   format = 'CSV',
10  uris = ['gs://bootcamp-data-analytics-public/CRM/
  european_users.csv'],
11  skip_leading_rows = 1
12 );

```

```

CREATE EXTERNAL TABLE `sprint3-analytics-albert.
sprint3_bronze.credit_cards_raw`
OPTIONS (
  format = 'CSV',
  uris = ['gs://bootcamp-data-analytics-public/CRM/
  credit_cards.csv'],
  skip_leading_rows = 1
);

```



Ejercicio 3: Carga de Datos Locales (Upload)

Falta el catálogo de Productos. Esta información no está en el Data Lake, utiliza el fichero products.csv del sprint 2.

» Carga este fichero manualmente ("Upload") al dataset sprint3_bronze y crea la tabla products_raw.

```
Consulta sin título
1 SELECT *
2 FROM `sprint3_bronze.products_raw`;
```

Recientes	Resultados de la consulta	Chat	View all jobs	Guardar los resultados	Abrir en
▼ 9:50 p.m.	< Información del trabajo Resultados Visualización JSON Detalles de la ejecución Gr >				
✓ SELECT * FROM `sprint...	Fila id product_name price colour				
▼ 9:46 p.m.	1 48 rock Renly in \$21.53 #9e9e9e				
✓ select* from `sprint3_br...	2 18 Karstark warden \$148.91 #c4c4c4				
	3 90 Winterfell \$39.73 #757575				
	4 96 dooku solo \$20.92 #282828				
	5 97 jinn Winterfell \$65.25 #bababa				
	Resultados por página: 50 1 – 50 de 100				

» Observa que esta será la única Mesa Nativa de momento.

Ejercicio 4: Arquitectura y Rendimiento. Materialización de Datos (Asistido por IA)

Escenario:

Las consultas sobre el Data Lake van lentas. Debes demostrar a tu mánager la diferencia de rendimiento entre trabajar con ficheros externos y trabajar con tablas nativas de BigQuery.

a) Materialización de Datos (Asistido por IA)

🌱 Tarea:

Crea una nueva tabla llamada **sprint3_bronze.transactions_raw_native** que sea una copia exacta de tu tabla externa **transactions_raw**.

Requisito de "AI-Pair Programming":

No escribas el código SQL manualmente. Utiliza el Asistente de IA (Gemini) integrado en BigQuery (o el chat lateral) para generar la sentencia.

👉 Tu Rol: Eres el responsable de validar que el código que te da la IA es correcto antes de ejecutarlo.

Prompt Sugerido:

"Write a SQL query to create a new table called transactions_raw_native in the sprint3_bronze dataset. It should contain all data from the transactions_raw table. Please use CREATE OR REPLACE TABLE so I don't get errors if I run it more than once."

🔑 **Entrega:**

Una captura de pantalla donde se vea:

» **El prompt que vas a escribir en la IA**

Write a SQL query to create a new table called transactions_raw_native in the sprint3_bronze sprint3-analytics-albert (dataset). It should contain all data from the transactions_raw table. Please use CREATE OR REPLACE TABLE so I don't get errors if I run it more than once.

» **El código SQL que la IA generó.**

```
CREATE OR REPLACE TABLE `sprint3-analytics-albert.sprint3_bronze.transactions_raw_native`  
AS  
SELECT * FROM `sprint3-analytics-albert.sprint3_bronze.transactions_raw`
```

Consulta sin tí... **Ejecutar** Guardar Descargar Compartir

```
1 CREATE OR REPLACE TABLE `sprint3-analytics-albert.sprint3_bronze.transactions_raw_native`  
2 AS  
3 SELECT * FROM `sprint3-analytics-albert.sprint3_bronze.transactions_raw`  
4
```

Resultados de...

[Chat](#)[View all jobs](#)

< Información del trabajo Resultados Detalles de la ejecución Gra >

ID de trabajo	sprint3-analytics-albert:EU.bquxjob_5e87d0fb_19e99700944 (Ver detalles de rendimiento)
Usuario	a.armentano73@gmail.com
Ubicación	EU
Hora de creación	5 jun 2026, 10:18:37 p.m. UTC+2
Hora de inicio	5 jun 2026, 10:18:37 p.m. UTC+2
Hora de finalización	5 jun 2026, 10:18:40 p.m. UTC+2
Duración	2 s
Bytes procesados	12.61 MB
Bytes facturados	13 MB
Milisegundos de ranura	3010
Prioridad del trabajo	INTERACTIVE
Usar SQL heredado	false
Tabla de destino	sprint3-analytics-albert.sprint3_bronze.transactions_raw_native
Motivos por los que	METADATA_CACHING_NOT_ENABLED: sprint3-analytics-

» El resultado de l'ejecución ("Esta afirmación creó una nueva tabla...").

[sprint3-analytics-albert](#) / [Datasets](#) / [sprint3_bronze](#) / [Tables](#) / [transactions_raw_native](#)

[transactions_r...](#)
[Consulta](#)
[Abrir en](#)

[Esquema](#)
[Detalles](#)
[Vista previa](#)
[Explorador de tablas](#)
[Vista previa](#)
[Estado](#)

[Filtro](#)
 Escribir el nombre o valor de la propiedad

☐	Nombre del campo	Tipo	Modo	Descripción	Clave
☐	id	STRING	NULLABLE	-	-
☐	card_id	STRING	NULLABLE	-	-
☐	business_id	STRING	NULLABLE	-	-
☐	timestamp	TIMESTAMP	NULLABLE	-	-
☐	amount	FLOAT	NULLABLE	-	-
☐	declined	INTEGER	NULLABLE	-	-
☐	product_ids	STRING	NULLABLE	-	-
☐	user_id	INTEGER	NULLABLE	-	-
☐	lat	FLOAT	NULLABLE	-	-
☐	longitude	FLOAT	NULLABLE	-	-

b) Auditoria de Costes

Tarea:

Diseñar una prueba para comparar el coste de leer una sola columna (ej: id) en la tabla externa vs. la tabla nativa. Utiliza los Bytes procesados y los Bytes facturados para hacer la comparación.

» ¿Cuánto "pesa" la consulta a transactions_raw?

[Consulta sin tí...](#)
[Ejecutar](#)
[Guardar](#)
[Descargar](#)

```

1 SELECT id
2 FROM `sprint3-analytics-albert.sprint3_bronze.transactions_raw`;
  
```

»¿Cuánto "pesa" la misma consulta a transactions_raw_native?

Consulta sin tí... Ejecutar Guardar Descargar

```
1 SELECT id
2 FROM `sprint3-analytics-albert.sprint3_bronze.transactions_raw_native`;
```

Resultados de...

<

Información del trabajo

Resultados

Visualización

ID de trabajo

sprint3-analytics-albert:EU.bquxjob_3bd9ca4b_19ea168903e
([Ver detalles de rendimiento](#))

Usuario

a.armentano73@gmail.com

Ubicación

EU

Hora de creación

7 jun 2026, 11:27:25 a.m. UTC+2

Hora de inicio

7 jun 2026, 11:27:25 a.m. UTC+2

Hora de finalización

7 jun 2026, 11:27:27 a.m. UTC+2

Duración

1 s

Bytes procesados

3.62 MB

Bytes facturados

10 MB

Milisegundos de ranura

737

Prioridad del trabajo

INTERACTIVE

Usar SQL heredado

false

Tabla de destino

[Tabla temporal](#)

👉 Entrega:

Capturas del validador mostrando la diferencia y una conclusión técnica.

c) El peligro del LIMIT

Muchos analistas piensan que poner LIMIT 10 reduce el coste de la consulta.

🔗 Tasca:

Haz un `SELECT * FROM transactions_raw_native LIMIT 10` sobre la mesa externa.

The screenshot shows a web browser with multiple tabs. The active tab is titled "Consulta sin tí...". Below the browser tabs, there is a header bar with a magnifying glass icon, the text "Consulta sin tí...", and three buttons: "Ejecutar" (Execute), "Guardar" (Save), and "Descargar" (Download). Below the header, a SQL query is displayed in a text area:

```
1 SELECT id
2 FROM `sprint3-analytics-albert.sprint3_bronze.transactions_raw_native`
3 LIMIT 10;
```

Below the query, there is a green checkmark icon and the text: "Esta consulta procesará 3.62 MB cuando se ejecute." Below this, there is a grey button with the text: "Se está usando la cuota de procesamiento según demanda".

☒ Comprobación: Mira el "Dry Run". ¿Ha bajado el coste respecto a no poner LIMIT? Explica brevemente por qué esto es una trampa para principiantes.

Biq Query:

- Lee y escanea toda la tabla y las columnas por igual.
- Precesa igual todos los bloques.
- Big Query es un motor columnado y distribuido.

CONCLUSIÓN: El LIMIT 10, limita el resultado, pero no el coste.

Ejercicio 5: Adaptación de Sintaxis (Reporting)

Tu jefe quiere saber cuáles fueron los 5 días con más ingresos del año 2021.

 Reto:

Probablemente el campo timestamp es un STRING. Deberás investigar funciones de BigQuery (SUBSTR, CAST, PARSE_TIMESTAMP) para filtrar el año y agrupar por fecha correctamente

Consulta sin tí... Ejecutar Guardar Descargar

```
1 SELECT
2   DATE(timestamp) AS dia,
3   ROUND(SUM(amount), 2) AS total_ingresos
4 FROM `sprint3-analytics-albert.sprint3_bronze.transactions_raw_native`
5 WHERE EXTRACT (YEAR FROM timestamp) = 2021
6 GROUP BY dia
7 ORDER BY total_ingresos
8 LIMIT 5;
9
```

✓ Se completó la consulta

Se está usando la cuota de procesamiento según demanda

Recientes

Resultados de...

▼ 12:01 p.m.

✓ SELECT DATE(timest...

▼ 12:00 p.m.

✓ SELECT DATE(timest...

▼ 11:57 a.m.

! SELECT DATE(timest...

▼ 11:57 a.m.

< Información del trabajo

Resultados

Fila	dia	total_ingresos
1	2021-08-13	1946.75
2	2021-07-09	3418.47
3	2021-06-05	3747.03
4	2021-06-10	3751.37
5	2021-11-16	3914.17

Resultados de...

ChatView all jobs

<

Información del trabajo

Resultados

Visualización

JSON

ID de trabajo

sprint3-analytics-albert:EU.bquxjob_41202de9_19ea1875aa7
(Ver detalles de rendimiento)

Usuario

a.armentano73@gmail.com

Ubicación

EU

Hora de creación

7 jun 2026, 12:01:03 p.m. UTC+2

Hora de inicio

7 jun 2026, 12:01:03 p.m. UTC+2

Hora de finalización

7 jun 2026, 12:01:04 p.m. UTC+2

Duración

0 s

Bytes procesados

1.53 MB

Bytes facturados

10 MB

Milisegundos de ranura

32

Prioridad del trabajo

INTERACTIVE

Usar SQL heredado

false

Tabla de destino

Tabla temporal

Etiquetas

Ejercicio 6: Consultas Complejas

Necesitamos un informe que cruce datos.

Tasca:

Lista el nombre, país y fecha de las transacciones realizadas por empresas que realizaron operaciones entre 100 y 200 euros en alguna de estas fechas: 29-04-2015, 20-07-2018 o 13-03-2024.

- No coinciden los atributos con la tabla. Borrar tabla.

Consulta sin título		Ejecutar	Guardar ▼	Descargar
1	<code>DROP TABLE IF EXISTS `sprint3-analytics-albert.sprint3_bronze.companies_raw`;</code>			
2				

- Creación de la nueva tabla. Coincidencia con los atributos para realizar la consulta.

Consulta sin título

Ejecutar Guardar Descargar Compartir

```
1 CREATE OR REPLACE EXTERNAL TABLE `sprint3-analytics-albert.sprint3_bronze.companies_raw`
2 (
3     company_id STRING,
4     company_name STRING,
5     phone STRING,
6     email STRING,
7     country STRING,
8     website STRING
9 )
10 OPTIONS (
11     format = 'CSV',
12     uris = ['gs://bootcamp-data-analytics-public/ERP/companies.csv'],
13     skip_leading_rows = 1,
14     field_delimiter = ','
15 );
```

- Consulta:

```
1 SELECT
2     c.company_name,
3     c.country,
4     DATE(t.timestamp) AS data_transaccio
5 FROM `sprint3-analytics-albert.sprint3_bronze.transactions_raw_native` AS t
6 JOIN `sprint3-analytics-albert.sprint3_bronze.companies_raw` AS c
7 ON t.business_id = c.company_id
8 WHERE t.amount BETWEEN 100 AND 200 AND DATE(t.timestamp) IN ('2015-04-29', '2018-07-20', '2024-03-13')
9 ORDER BY data_transaccio;
```

- Resultado consulta:

ID de trabajo	sprint3-analytics-albert:EU.bquxjob_214aae98_19ea2054374
Usuario	a.armentano73@gmail.com
Ubicación	EU
Hora de creación	7 jun 2026, 2:18:35 p.m. UTC+2
Hora de inicio	7 jun 2026, 2:18:35 p.m. UTC+2
Hora de finalización	7 jun 2026, 2:18:36 p.m. UTC+2
Duración	0 s
Bytes procesados	2.3 MB
Bytes facturados	20 MB
Milisegundos de ranura	11132
Prioridad del trabajo	INTERACTIVE
Usar SQL heredado	false
Tabla de destino	Tabla temporal

Recientes	Resultados de la consulta			
		Chat	View all jobs	
▼ 2:18 p.m.	<	Información del trabajo	Resultados	Visualización JSON
✓ SELECT c.company_na...	Fila	company_name	country	data_transaccio
	1	Donec Fringilla PC	France	2015-04-29
	2	Non Magna LLC	United Kingdom	2015-04-29
	3	Ac Libero Inc.	United Kingdom	2015-04-29
	4	Amet Lorem LLP	Spain	2015-04-29
	5	Auctor Mauris Vel LLP	United States	2015-04-29
	6	Dictum Eu Corp.	Canada	2015-04-29
	7	Tempor Diam Institute	Netherlands	2018-07-20
	8	Tempor Diam Institute	Netherlands	2018-07-20
	9	Et Magnis Ltd	Belgium	2018-07-20
	10	Justo Eu Arcu Ltd	Italy	2018-07-20
	11	Netus Et Malesuada Ltd	Netherlands	2018-07-20
	12	Aliquam Erat Volutpat LLP	Italy	2018-07-20

Nivel 2: Limpieza y Transformación (ELT)

Escenario:
Los datos brutos tienen problemas de calidad (símbolos de moneda, usuarios duplicados, fechas incorrectas). Actúa como Data Engineer para limpiarlo todo.

Ejercicio 1: Limpieza de Productos (Data Quality)

Crearemos la capa limpia ("Silver") para los productos. Tienes la tabla sprint3_bronze.products_raw cargada desde el CSV. El equipo de Data Governance te pide crear una tabla de productos limpia en sprint3_silver.products_clean que cumpla estas reglas de calidad:

CREACIÓN de la Tabla products_clean;

```
1 CREATE OR REPLACE TABLE `sprint3-analytics-albert.sprint3_silver.products_clean` AS
```

» **Estandarización de Nombres:** La columna original id es ambigua; renombrándola a product_id. La columna product_name simplificala a name.

```
3 -- RENOMBRAR las columnas
4 id AS product_id,
5 product_name AS name,
```

» **Limpieza de IDs:** El campo warehouse_id tiene el formato antiguo "WH-4". Elimina el prefijo "WH-" y convierte el valor a número entero (INT64).

```
7 -- LIMPIEZA de warehouse_id: ELIMINAR 'WH-' y CONVERTIR a INT64
8 CAST(REPLACE(warehouse_id, 'WH-', '' ) AS INT64) AS warehouse_id,
```

» **Garantía de Precio:** Asegúrate de que price es un número (FLOAT64), sin símbolos de moneda.

```
10 -- LIMPIEZA de price: ELIMINAR símbolos y CONVERTIR a FLOAT64
11 CAST(REPLACE(price, '$', '' ) AS FLOAT64) AS price,
```

» **Otras columnas: Conserva el campo weight (peso) tal cual.**

- **CONSULTA COMPLETA:**

```
1 CREATE OR REPLACE TABLE `sprint3-analytics-albert.sprint3_silver.products_clean` AS
2 SELECT
3   id AS product_id,
4   product_name AS name,
5
6   CAST(REPLACE(warehouse_id, 'WH-', '' ) AS INT64) AS warehouse_id,
7
8   CAST(REPLACE(price, '$', '' ) AS FLOAT64) AS price,
9
10  weight
11 FROM `sprint3-analytics-albert.sprint3_bronze.products_raw`;
```

ID de trabajo	sprint3-analytics-albert:EU.bquxjob_20900ac7_19ea2dc6396
Usuario	a.armentano73@gmail.com
Ubicación	EU
Hora de creación	7 jun 2026, 6:13:34 p.m. UTC+2
Hora de inicio	7 jun 2026, 6:13:34 p.m. UTC+2
Hora de finalización	7 jun 2026, 6:13:35 p.m. UTC+2
Duración	1 s
Bytes procesados	4.69 KB
Bytes facturados	10 MB
Milisegundos de ranura	632
Prioridad del trabajo	INTERACTIVE
Usar SQL heredado	false
Tabla de destino	sprint3-analytics-albert.sprint3_silver.products_clean
Etiquetas	

Ejercicio 2: Creación de Transacciones Limpias (Capa Silver)

- Escenario:
- La tabla **transactions_raw (Bronze)** es insegura: el importe (amount) podría tener letras, las coordenadas podrían fallar y la fecha es un texto difícil de filtrar. Crearemos la tabla definitiva **sprint3_silver.transactions_clean** que garantice lo siguiente.
- Obtener toda la información del contenido de la tabla **transactions_raw**:

```

3
4 SELECT
5     column_name,
6     data_type
7 FROM `sprint3-analytics-albert.sprint3_bronze.INFORMATION_SCHEMA.COLUMNS`
8 WHERE table_name = 'transactions_raw';

```

Información del trabajo		Resultados
column_name ▼		data_type ▼
1	id	STRING
2	card_id	STRING
3	business_id	STRING
4	timestamp	TIMESTAMP
5	amount	FLOAT64
6	declined	INT64
7	product_ids	STRING
8	user_id	INT64
9	lat	FLOAT64
10	longitude	FLOAT64

- **CREACIÓN** de la tabla:

```
1 CREATE OR REPLACE TABLE `sprint3-analytics-albert.sprint3_silver.transactions_clean` AS
```

» Estandarización de Nombres: La columna original id es ambigua; renomenala a transaction_id.

```
4 -- CAMBIO de nombre
5 id AS transaction_id,
```

» Robustez en Importes: Utiliza SAFE_CAST en el campo amount. Si falla, susstituyéndolo por 0 (usando IFNULL).

```
7 -- 2) ROBUSTEZ en los importes
8 IFNULL(SAFE_CAST(amount AS FLOAT64), 0) AS amount,
```

» Fechas Reales: Convierte el campo timestamp (que es STRING) a tipo TIMESTAMP real

```
10 -- 3) Timestamp ya era TIMESTAMP
11 timestamp,
```

» Coordenadas: Asegura que lat y longitude sean FLOAT64 (utiliza SAFE_CAST por seguridad).

```
13 -- 4) CORDENADES limpias
14 SAFE_CAST(lat AS FLOAT64) AS lat,
15 SAFE_CAST(longitude AS FLOAT64) AS longitude,
```

»Desglose de Productos: Transforma la cadena de texto product_ids en un ARRAY de enteros.

- *Input:* "1, 2, 3" (String)
- *Output:* [1, 2, 3] (Array/Lista de enteros)

```
17  -- 5) DESGLOSE de Productos: STRING → ARRAY<INT64>
18  ARRAY(
19    SELECT CAST(TRIM(x) AS INT64)
20    FROM UNNEST(SPLIT(product_ids, ',')) AS x
21  ) AS product_ids,
```

» Resto de campos: Mantenlos igual.

```
23  -- 6) los otros campos igual
24  card_id,
25  business_id,
26  declined,
27  user_id
28  FROM `sprint3-analytics-albert.sprint3_bronze.transactions_raw`;
```

☐	Nombre del campo	Tipo	Modo
☐	transaction_id	STRING	NULLABLE
☐	amount	FLOAT	NULLABLE
☐	timestamp	TIMESTAMP	NULLABLE
☐	lat	FLOAT	NULLABLE
☐	longitude	FLOAT	NULLABLE
☐	product_ids	INTEGER	REPEATED
☐	card_id	STRING	NULLABLE
☐	business_id	STRING	NULLABLE
☐	declined	INTEGER	NULLABLE
☐	user_id	INTEGER	NULLABLE

Ejercicio 3: Unificación de Usuarios (UNION)

Tenemos los usuarios fragmentados por región.

🔗 Tarea:

Crea la tabla `sprint3_silver.users_combined`. Utiliza `UNION ALL` para unificar a los usuarios de los EE. UU. y Europa en una única lista maestra. Añade una columna calculada para saber de dónde vienen.

» Estandarización de Nombres: La columna original `id` es ambigua; renómbrala a `user_id`.

```
1  -- Ejercicio 3: UNIFICACIÓN DE USUARIOS (UNION) y CAMBIO de nombre columna -id a -user_id:
2
3  CREATE OR REPLACE TABLE `sprint3-analytics-albert.sprint3_silver.users_combined` AS
4  SELECT
5      id AS user_id,
6      name,
7      surname,
8      phone,
9      email,
10     birth_date,
11     country,
12     city,
13     postal_code,
14     address,
15     'USA' AS origin
16 FROM `sprint3-analytics-albert.sprint3_bronze.american_users_raw`
17
18 UNION ALL
19
20 SELECT
21     id AS user_id,
22     name,
23     surname,
24     phone,
25     email,
26     birth_date,
27     country,
28     city,
29     postal_code,
30     address,
31     'EU' AS origin
32 FROM `sprint3-analytics-albert.sprint3_bronze.european_users_raw`;
33
```

ID de trabajo	sprint3-analytics-albert:EU.bquxjob_43a22bf3_19ea35ba5e6
Usuario	a.armentano73@gmail.com
Ubicación	EU
Hora de creación	7 jun 2026, 8:32:33 p.m. UTC+2
Hora de inicio	7 jun 2026, 8:32:34 p.m. UTC+2
Hora de finalización	7 jun 2026, 8:32:35 p.m. UTC+2
Duración	1 s
Bytes procesados	568.04 KB
Bytes facturados	20 MB
Milisegundos de ranura	873
Prioridad del trabajo	INTERACTIVE
Usar SQL heredado	false
Tabla de destino	sprint3-analytics-albert.sprint3_silver.users_combined
Motivos por los que no se usó la caché de metadatos	METADATA_CACHING_NOT_ENABLED: sprint3-analytics-albert.sprint3_bronze.european_users_raw, sprint3-analytics-albert.sprint3_bronze.american_users_raw
Etiquetas	

Ejercicio 4: Materialización de Compañías y Tarjetas de Crédito

Escenario:

Para completar el modelo de datos en la capa Silver, nos faltan dos dimensiones clave que actualmente dependen de ficheros CSV externos: Compañías y Tarjetas de Crédito. No podemos depender de ficheros sueltos para el análisis final. Debemos importar estos datos a tablas nativas (Silver) y aprovechar para corregir formatos.

🧩 Tareas:

» 1. Crea la tabla `sprint3_silver.companias_clean`. Copia los datos tal cual, pero asegúrate de que sea una tabla nativa de BigQuery (no una vista externa).

```

1  -- Ejercicio 4.1: Materialización de Compañías (Silver)
2
3
4  CREATE OR REPLACE TABLE `sprint3-analytics-albert.sprint3_silver.companies_clean` AS
5  SELECT
6      company_id,
7      company_name,
8      phone,
9      email,
10     country,
11     website
12  FROM `sprint3-analytics-albert.sprint3_bronze.companies_raw`;
13

```

Resultados de...

ChatView all jobs

<Información del trabajoResultadosDetalles de la ejecución

ID de trabajo

sprint3-analytics-albert:EU.bquxjob_332e6111_19ea35ed26b
(Ver detalles de rendimiento)

Usuario

a.armentano73@gmail.com

Ubicación

EU

Hora de creación

7 jun 2026, 8:36:01 p.m. UTC+2

Hora de inicio

7 jun 2026, 8:36:02 p.m. UTC+2

Hora de finalización

7 jun 2026, 8:36:03 p.m. UTC+2

Duración

1 s

Bytes procesados

10.1 KB

Bytes facturados

10 MB

Milisegundos de ranura

967

Prioridad del trabajo

INTERACTIVE

Usar SQL heredado

false

Tabla de destino

sprint3-analytics-albert.sprint3_silver.companies_clean

Motivos por los que

METADATA_CACHING_NOT_ENABLED: sprint3-analytics-

» 2. Crea la tabla `sprint3_silver.credit_cards_clean`. Copia los datos tal cual, pero asegúrate de que sea una tabla nativa de BigQuery (no una vista externa).

Consulta sin título

Ejecutar

Guardar

Descargar

Compartir

```
1  -- EJERCICIO 4.2: Materialización de Tarjetas de Crédito (Silver)
2
3  CREATE OR REPLACE TABLE `sprint3-analytics-albert.sprint3_silver.credit_cards_clean` AS
4  SELECT
5      id AS credit_card_id,
6      user_id,
7      iban,
8      pan,
9      pin,
10     cvv,
11     track1,
12     track2,
13     expiring_date
```

Se completó la consulta

Resultados de...		Chat	View all jobs
Información del trabajo		Resultados	Detalles de la ejecución
ID de trabajo	sprint3-analytics-albert:EU.bquxjob_769af2a_19ea3667de3 (Ver detalles de rendimiento)		
Usuario	a.armentano73@gmail.com		
Ubicación	EU		
Hora de creación	7 jun 2026, 8:44:24 p.m. UTC+2		
Hora de inicio	7 jun 2026, 8:44:24 p.m. UTC+2		
Hora de finalización	7 jun 2026, 8:44:25 p.m. UTC+2		
Duración	1 s		
Bytes procesados	804.85 KB		
Bytes facturados	10 MB		
Milisegundos de ranura	1119		
Prioridad del trabajo	INTERACTIVE		
Usar SQL heredado	false		
Tabla de destino	sprint3-analytics-albert.sprint3_silver.credit_cards_clean		

Si es necesario, renombrar el id según corresponda.

Nivel 3: Presentación de Datos y Creación de Vistas

Escenario:

En el nivel anterior vas a actuar como Data Engineer limpiando los datos (_clean). Ahora toca ponerse el sombrero de Analista de Negocio. El problema actual es que las tablas están separadas y algunas tienen formatos difíciles de explotar (como la lista de productos comprimida en

una sola celda). En este nivel crearás Vistas para facilitar el acceso a la información y generarás informes finales.

🎯 **Objetivos:**

- » Crear Vistas (CREATE VIEW) para encapsular lógica de negocio compleja.
- » Resolver el reto de datos agrupados en strings (Split + UNNEST).
- » Exportar resultados para terceros (Reverse ETL).

Ejercicio 1: La Vista de Marketing (Lógica de Negocio)

Marketing necesita segmentar a los clientes corporativos, pero no saben hacerlo. Tu tarea es dejarles la información preparada.

🔗 **Tarea:**

Crea una vista llamada `sprint3_gold.v_marketing_kpis` que muestre la siguiente información para cada compañía:

- » Nombre de la compañía, Teléfono y País (origen: `companies_clean`).
- » Media de compra (AVG(amount) de `transactions_clean`).
- » Clasificación de Cliente (Lógica):
- Crea una columna calculada llamada `client_tier`.
- Si la media de compra es superior a 260€, etiqueta como "Premium".
- Si es igual o inferior, etiqueta como "Standard".

```
1 CREATE OR REPLACE VIEW `sprint3_gold.v_marketing_kpis` AS
2 SELECT
3     c.company_name AS company_name,
4     c.phone AS phone,
5     c.country AS country,
6     AVG(t.amount) AS avg_amount,
7     CASE
8         WHEN AVG(t.amount) > 260 THEN 'Premium'
9         ELSE 'Standard'
10    END AS client_tier
11 FROM `sprint3_silver.companies_clean` AS c
12 JOIN `sprint3_silver.transactions_clean` AS t
13 ON c.company_id = t.business_id
14 GROUP BY
15     c.company_name,
16     c.phone,
17     c.country;
```

- **Campos-Vista:** `sprint3_gold.v_marketing_kpis`:

☐	Nombre del campo	Tipo	Modo
☐	company_name	STRING	NULLABLE
☐	phone	STRING	NULLABLE
☐	country	STRING	NULLABLE
☐	avg_amount	FLOAT	NULLABLE
☐	client_tier	STRING	NULLABLE

👉 Entrega:

Realiza una consulta SELECT * sobre tu nueva vista, ordenando los resultados para que aparezcan primero los clientes "Premium" y, dentro de estos, los que tengan mayor promedio de compra.

Consulta sin título

Ejecutar

Compartir ▼

```

1 SELECT *
2 FROM `sprint3_gold.v_marketing_kpis`
3 ORDER BY
4     CASE WHEN client_tier = 'Premium' THEN 1 ELSE 2 END,
5     avg_amount DESC;

```

<	Información del trabajo	Resultados	Visualización	JSON	Detalles de la ejecución
ID de trabajo	sprint3-analytics-albert:EU.bquxjob_1d18369e_19eab96c468	(Ver detalles de rendimiento)			
Usuario	a.armentano73@gmail.com				
Ubicación	EU				
Hora de creación	9 jun 2026, 10:54:04 a.m. UTC+2				
Hora de inicio	9 jun 2026, 10:54:05 a.m. UTC+2				
Hora de finalización	9 jun 2026, 10:54:05 a.m. UTC+2				
Duración	0 s				
Bytes procesados	1.53 MB				
Bytes facturados	20 MB				
Milisegundos de ranura	75				
Prioridad del trabajo	INTERACTIVE				
Usar SQL heredado	false				
Tabla de destino	Tabla temporal				

Ejercicio 2: Ranking de Productos (La Potencia de los Arrays)

Escenario de Negocio:

El equipo de ventas quiere optimizar el catálogo. Necesitan un informe en la capa Gold que muestre el rendimiento real de cada producto. Gracias a tu buena ingeniería en la capa Silver, la tabla `transactions_clean` ya tiene los IDs de producto perfectamente organizados en una lista (Array). Ahora toca explotar esta estructura.

Objetivo:

Crea la tabla `sprint3_gold.product_salas_ranking` que contenga el inventario completo de productos y cuántas veces se ha vendido cada uno.

Requisitos del Informe:

- » Detalle del Producto: Debe incluir `product_id`, `name`, `price` y `color` (vienen de la tabla `products_clean`).
- » Métrica de Negocio: Una columna nueva `total_sold` que cuente cuántas veces aparece este producto en las transacciones.
- » Integridad: Deben aparecer todos los productos, incluso los que tienen 0 ventas (quizás hay que descatalogarlos).

Pista Técnica:

- » En `transactions_clean`, los productos están "encapsulados" dentro de un Array por cada transacción.
- » Primero necesitarás "aplanar" la mesa de transacciones usando `UNNEST(product_ids)` para poder contar los productos individualmente.
- » Después, haz un cruce (`LEFT JOIN`) empezando por la mesa de productos para no perder aquellos que no se han vendido nunca.

```

1 CREATE OR REPLACE TABLE `sprint3_gold.product_sales_ranking` AS
2 WITH exploded AS (
3     SELECT
4         t.transaction_id,
5         product_id
6     FROM `sprint3_silver.transactions_clean` t,
7     UNNEST(t.product_ids) AS product_id
8 )
9 SELECT
10     p.product_id,
11     p.name,
12     p.price,
13     COUNT(e.product_id) AS total_sold
14 FROM `sprint3_silver.products_clean` p
15 LEFT JOIN exploded e
16     ON p.product_id = e.product_id
17 GROUP BY
18     p.product_id,
19     p.name,
20     p.price
21 ORDER BY total_sold DESC;

```

[←](#)
[Información del trabajo](#)
[Resultados](#)
[Detalles de la ejecución](#)

ID de trabajo	sprint3-analytics-albert:EU.bquxjob_41c4c28_19eabb38d2a detalles de rendimiento ↗)
Usuario	a.armentano73@gmail.com
Ubicación	EU
Hora de creación	9 jun 2026, 11:25:31 a.m. UTC+2
Hora de inicio	9 jun 2026, 11:25:31 a.m. UTC+2
Hora de finalización	9 jun 2026, 11:25:33 a.m. UTC+2
Duración	1 s
Bytes procesados	1.94 MB
Bytes facturados	20 MB
Milisegundos de ranura	17084
Prioridad del trabajo	INTERACTIVE
Usar SQL heredado	false

Filtro Escribir el nombre o valor de la propiedad			
☐	Nombre del campo	Tipo	Modo
☐	product_id	INTEGER	NULLABLE
☐	name	STRING	NULLABLE
☐	price	FLOAT	NULLABLE
☐	total_sold	INTEGER	NULLABLE

< Información del trabajo Resultados Visualización JSON Detalle >					
Fila	product_id	name	price	total_sold	
1	52	riverlands the duel	31.52	2654	
2	29	Tully maester Tarly	167.2	2635	
3	21	duel Direwolf	96.9	2609	
4	16	the duel warden	180.91	2608	

- Ejercicio 3: Exportación de Resultados
 - Tu mánager no tiene acceso a BigQuery y quiere el listado de "Top Productos" en un Excel para una reunión.
 -  Tarea:
 - Exporta los datos de la tabla product_sales_ranking a Google Sheets o baja el archivo CSV localmente.
 -  Entrega:
 - Una captura de pantalla donde se vea el archivo abierto (Excel/Sheets) con los datos correctamente formados.
 - Objetivos
 - Conectar BigQuery a un Data Lake corporativo (GCS) utilizando código SQL (DDL).
 - Diferenciar entre Tablas Externas y Nativas y su impacto en los costes.
 - Utilizar IA Generativa para acelerar la creación de código.
 - Realizar procesos de limpieza y unificación de datos robustos (SAFE_CAST).Duración:
 - 4 días.
 - Entrega:Revisa el material a entregar en cada ejercicio.
 - Código e Infraestructura (.sql) Los archivos .sql con todos los scripts generados.

- Evidencia de Ejecución y Rendimiento (PDF) Un documento PDF único que contenga las capturas de pantalla de la Consola de BigQuery para cada ejercicio.
- Requisito Crítico: Para validar que tu optimización funciona, la captura debe mostrar claramente:
- El código SQL al editor.
- El mensaje de validación (check verde ☒) o la pestaña Job Information donde se vean los Bytes procesados (Bytes processed).
- Importante
- Recuerda revisar las mejores prácticas antes de hacer la entrega.
- Mejores prácticas